Perbandingan Kinerja Logistic Regression dan Random Forest dalam Deteksi Fraud Transaksi Kartu Kredit pada Data Tidak Seimbang

Aisyah Artika Sari[1], Anisa Suci Qomarah[2], Mohsen Bandar Abdulqader Al-Mhiqani [3]

[123] Program Studi Ilmu Komputer, Fakultas Teknik dan Sains, Universitas Muhammadiyah Bangka Belitung, Indonesia

aisyahartikasari9@gmail.com, anisasuciq@gmail.com, mohsenbandar801@gmail.com,

Abstrak

Deteksi fraud transaksi kartu kredit menjadi tantangan penting akibat karakteristik data yang sangat tidak seimbang. Penelitian ini membandingkan kinerja Logistic Regression (LR) dan Random Forest (RF) dalam mendeteksi transaksi fraud. Metode yang digunakan meliputi preprocessing data, pembagian data latih dan uji dengan rasio 80:20 menggunakan *stratified sampling*, serta evaluasi kinerja berdasarkan metrik precision, recall, dan F1-score. Hasil penelitian menunjukkan bahwa Random Forest memiliki kinerja lebih baik dibandingkan Logistic Regression dalam mendeteksi transaksi fraud pada data tidak seimbang.

Kata kunci Deteksi fraud, data tidak seimbang, Logistic Regression, Random Forest

Abstract

Credit card fraud detection remains a major challenge due to the highly imbalanced nature of transaction data. This study compares the performance of Logistic Regression (LR) and Random Forest (RF) in detecting fraudulent transactions. The proposed methodology includes data preprocessing, stratified data splitting with an 80:20 training–testing ratio, and performance evaluation using precision, recall, and F1-score. Experimental results show that Random Forest outperforms Logistic Regression in detecting fraud transactions on imbalanced datasets.

Keywords *fraud detection, imbalanced data, Logistic Regression, Random Forest*

I. PENDAHULUAN

Perkembangan teknologi digital telah mendorong peningkatan signifikan pada transaksi keuangan non-tunai, khususnya melalui penggunaan kartu kredit dan layanan berbasis *e-commerce* [1] [2]. Peningkatan volume transaksi pembayaran elektronik dalam skala besar memperluas peran sistem pembayaran elektronik dalam aktivitas keuangan modern, sekaligus meningkatkan kompleksitas pengelolaan transaksi oleh institusi keuangan [3]. Seiring dengan semakin beragamnya pola transaksi yang dihasilkan, tantangan dalam menjaga keamanan dan keandalan sistem pembayaran elektronik juga meningkat, terutama terkait risiko fraud pada transaksi keuangan digital [4] [5].

Dalam konteks tersebut, fraud transaksi kartu kredit menjadi salah satu bentuk kejahatan finansial yang paling menantang untuk ditangani [6] [7]. Meskipun jumlah transaksi fraud relatif kecil dibandingkan total transaksi, kondisi ini membentuk distribusi data yang sangat tidak seimbang, dengan transaksi normal sebagai kelas mayoritas. Ketidakseimbangan data tersebut menyulitkan proses pemodelan karena model klasifikasi cenderung bias terhadap kelas mayoritas dan kurang sensitif dalam mendeteksi transaksi fraud [8] [9]. Dampak dari permasalahan ini tercermin pada besarnya kerugian finansial global akibat fraud kartu kredit yang mencapai sekitar USD 33,83 miliar pada tahun 2023 [10] [2]. Tingginya risiko dan kerugian akibat fraud kartu kredit mendorong banyak penelitian untuk mengkaji pendekatan berbasis machine learning dalam mendeteksi transaksi fraud secara efektif. Berbagai penelitian terdahulu telah mengkaji deteksi fraud transaksi kartu kredit menggunakan pendekatan machine learning dengan beragam algoritma klasifikasi. Studi oleh [2] [6] menunjukkan bahwa Logistic Regression masih banyak digunakan sebagai metode baseline karena kesederhanaan model, stabilitas performa, serta kemudahan interpretasi dalam menganalisis hubungan antara fitur transaksi dan probabilitas terjadinya fraud. Di sisi lain, Random Forest sebagai metode ensemble dilaporkan mampu memberikan kinerja yang lebih unggul dalam mendeteksi fraud transaksi kartu kredit, terutama pada data dengan karakteristik kompleks dan heterogen. Penelitian oleh [3] [7] menunjukkan bahwa Random Forest memiliki kemampuan yang lebih baik dalam menangkap hubungan non-linear dan interaksi antarfitur dibandingkan model linear, sehingga lebih adaptif terhadap pola transaksi fraud yang dinamis. Meskipun demikian, masih terbatas kajian yang membandingkan secara sistematis kinerja model linear dan ensemble pada data transaksi yang sangat tidak seimbang dengan menggunakan metrik evaluasi yang sensitif terhadap kelas minoritas.

Berdasarkan celah penelitian tersebut, kebaruan penelitian ini terletak pada perbandingan sistematis antara Logistic Regression dan Random Forest dalam mendeteksi fraud transaksi kartu kredit pada data yang sangat tidak seimbang. Penelitian ini menekankan penggunaan metrik evaluasi yang sensitif terhadap kelas minoritas, seperti precision, recall, dan F1-score, untuk memberikan penilaian kinerja model yang lebih representatif dalam konteks deteksi fraud. Penelitian ini bertujuan untuk membandingkan kinerja algoritma Logistic Regression dan Random Forest dalam mendeteksi fraud transaksi kartu kredit pada data transaksi yang tidak seimbang dengan menggunakan metrik precision, recall, dan F1-score guna memperoleh gambaran yang lebih akurat mengenai efektivitas masing-masing algoritma.

II. TINJAUAN PUSTAKA

Deteksi fraud transaksi kartu kredit telah banyak diteliti menggunakan pendekatan *machine learning* untuk mengidentifikasi pola

transaksi mencurigakan pada sistem pembayaran elektronik [1] [2]. Berbagai penelitian menunjukkan bahwa tantangan utama dalam deteksi fraud meliputi tingginya volume transaksi, kompleksitas perilaku pengguna, serta distribusi data yang tidak seimbang, di mana transaksi fraud hanya merepresentasikan sebagian kecil dari keseluruhan data [3] [4].

Dalam konteks tersebut, Logistic Regression, sebagaimana ditunjukkan dalam beberapa penelitian terdahulu [2] [6] banyak digunakan sebagai model dasar (*baseline*) dalam deteksi fraud karena kesederhanaan model, stabilitas performa, dan kemudahan interpretasinya. Namun, karena bersifat linear, Logistic Regression memiliki keterbatasan dalam menangkap hubungan non-linear dan interaksi kompleks antarfitur, sehingga kinerjanya cenderung menurun ketika diterapkan pada data transaksi yang heterogen dan dinamis [6].

Sebagai alternatif, pendekatan *ensemble* seperti Random Forest, berdasarkan penelitian terdahulu [3] [7], menunjukkan kemampuan yang lebih baik dalam meningkatkan kinerja deteksi fraud dengan menangkap hubungan non-linear dan interaksi antarfitur secara lebih efektif dibandingkan model linear. Meskipun demikian, beberapa penelitian juga mencatat bahwa peningkatan kinerja tersebut sering diiringi dengan berkurangnya tingkat interpretabilitas model serta meningkatnya kebutuhan komputasi.

Selain Logistic Regression dan Random Forest, penelitian lain juga mengeksplorasi algoritma seperti Support Vector Machine serta metode *ensemble* berbasis *boosting* untuk deteksi fraud transaksi kartu kredit [5] [8]. Pendekatan-pendekatan tersebut mampu meningkatkan kinerja klasifikasi dalam kondisi tertentu, namun sering kali memerlukan penyesuaian parameter yang kompleks dan memiliki keterbatasan dalam hal skalabilitas pada data transaksi berskala besar [8] [9]

Secara umum, penelitian terdahulu masih memiliki keterbatasan karena sebagian besar studi mengevaluasi kinerja model secara individual tanpa melakukan perbandingan langsung antara model linear dan *ensemble* pada kondisi data transaksi yang sangat tidak seimbang. Selain itu, penggunaan metrik evaluasi umum seperti *accuracy* masih sering ditemukan, sehingga kemampuan model dalam mendeteksi transaksi fraud sebagai kelas minoritas belum tergambarkan secara optimal [3] [9]. Oleh karena itu, kajian yang membandingkan secara langsung kinerja Logistic Regression dan Random Forest pada dataset yang sama dengan menggunakan metrik precision, recall, dan F1-score masih relatif terbatas.

III. METODOLOGI PENELITIAN

Penelitian ini dilakukan melalui beberapa tahapan utama yang meliputi penggunaan dataset, prapemrosesan data, pelatihan model, dan evaluasi kinerja.

A. Dataset

Dataset yang digunakan dalam penelitian ini merupakan dataset transaksi kartu kredit yang banyak digunakan sebagai *benchmark* dalam penelitian deteksi fraud dan merepresentasikan

kondisi nyata sistem pembayaran elektronik. Dataset terdiri dari 284.807 transaksi dengan 30 atribut, di mana 28 fitur (V1–V28) merupakan hasil transformasi *Principal Component Analysis* (PCA) untuk menjaga kerahasiaan data pengguna, serta dua fitur tambahan yaitu Time yang merepresentasikan waktu terjadinya transaksi dan Amount yang menunjukkan nilai transaksi. Label target Class digunakan untuk membedakan transaksi normal (Class = 0) dan transaksi fraud (Class = 1). Distribusi kelas pada dataset bersifat sangat tidak seimbang, dengan 492 transaksi fraud dan sisanya merupakan transaksi normal, yang mencerminkan karakteristik nyata kasus fraud kartu kredit

B. Data Preprocessing

Tahap *preprocessing* dilakukan untuk memastikan data siap digunakan dalam proses pemodelan. Dataset diperiksa untuk memastikan tidak terdapat *missing values* serta seluruh fitur numerik berada dalam format yang sesuai guna meningkatkan stabilitas pembelajaran model (Carcillo *et al.*, 2021; Leevy *et al.*, 2023). Atribut Amount dinormalisasi agar berada pada skala yang seragam dan tidak mendominasi fitur lain selama pelatihan model (Hafez *et al.*, 2024). Selanjutnya, dataset dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan *stratified sampling* untuk mempertahankan proporsi kelas fraud dan non-fraud, sehingga evaluasi model tetap representatif (Btoush *et al.*, 2023)

C. Model Selection

Penelitian ini menggunakan dua algoritma klasifikasi, yaitu Logistic Regression dan Random Forest, yang memiliki karakteristik pemodelan yang berbeda.

1. Logistic Regression

Logistic Regression merupakan model klasifikasi linear yang memodelkan probabilitas suatu transaksi termasuk ke dalam kelas fraud. Model ini menggunakan fungsi logistik (sigmoid) untuk memetakan kombinasi linear fitur ke dalam rentang probabilitas $[0, 1]$.

Secara matematis, Logistic Regression dirumuskan sebagai berikut:

$$z=\beta 0+\beta 1x1+\beta 2x2+\cdots+\beta nxn \quad (1)$$

$$P(y = 1 \mid x) = \frac{1}{1+e^{-z}} \quad (2)$$

2. Random Forest

Random Forest merupakan metode ensemble learning yang membangun sejumlah *decision tree* dan menggabungkan hasil prediksinya melalui mekanisme voting. Setiap *decision tree* dilatih menggunakan subset data dan subset fitur yang dipilih secara acak. Prediksi akhir Random Forest diperoleh berdasarkan voting mayoritas dari seluruh ***decision tree*** dalam hutan, yang dapat dirumuskan sebagai berikut:

$$P(y = 1 \mid x) = 1 / (1 + e^{-z}) \quad (3)$$

Pendekatan ini memungkinkan Random Forest menangkap hubungan non-linear dan

interaksi kompleks antarfitur, sehingga lebih adaptif terhadap pola fraud yang dinamis.

D. Model Training

Tahap *model training* dilakukan untuk membangun model klasifikasi yang mampu membedakan transaksi normal dan transaksi fraud berdasarkan pola yang dipelajari dari data. Dataset hasil *preprocessing* dibagi menjadi data latih (80%) dan data uji (20%) menggunakan *stratified sampling* untuk mempertahankan proporsi kelas fraud dan non-fraud, mengingat karakteristik data yang sangat tidak seimbang.

Dua algoritma klasifikasi dilatih secara terpisah, yaitu Logistic Regression dan Random Forest. Logistic Regression digunakan sebagai model *baseline* untuk mempelajari hubungan linear antara fitur transaksi dan probabilitas terjadinya fraud. Sementara itu, Random Forest dilatih sebagai metode *ensemble learning* yang membangun sejumlah *decision tree* menggunakan subset data dan fitur yang dipilih secara acak, sehingga mampu menangkap hubungan non-linear dan interaksi kompleks antarfitur.

Kedua model menghasilkan keluaran berupa probabilitas transaksi fraud pada data uji. Probabilitas tersebut dikonversi menjadi label kelas dengan menerapkan nilai ambang batas (*threshold*) tertentu. Selain *threshold* standar, beberapa nilai *threshold* juga dievaluasi untuk menganalisis pengaruhnya terhadap kinerja model pada kondisi data tidak seimbang, dengan penekanan pada kemampuan mendeteksi transaksi fraud sebagai kelas minoritas.

E. Model Evaluation

Evaluasi kinerja model dilakukan untuk menilai kemampuan algoritma Logistic Regression dan Random Forest dalam mendeteksi transaksi fraud pada dataset kartu kredit dengan distribusi kelas yang sangat tidak seimbang. Evaluasi dilakukan menggunakan data uji sebesar 20% yang tidak digunakan selama proses pelatihan, sehingga hasil evaluasi mencerminkan kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Mengingat karakteristik data yang tidak seimbang, metrik accuracy tidak digunakan sebagai ukuran utama karena berpotensi memberikan gambaran performa yang menyesatkan. Oleh karena itu, evaluasi kinerja model difokuskan pada metrik yang lebih sensitif terhadap kelas minoritas, yaitu precision, recall, dan F1-score, yang dinilai lebih representatif dalam konteks deteksi fraud.

Secara matematis, metrik evaluasi dirumuskan sebagai berikut:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{4}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{5}$$

$$\text{F1-score} = \frac{2 \times (\text{Precision} \times \text{Recall})}{\text{Precision} + \text{Recall}} \tag{6}$$

dengan TP (True Positive) menyatakan jumlah transaksi fraud yang terdeteksi dengan

benar, FP (False Positive) menyatakan jumlah transaksi normal yang salah diklasifikasikan sebagai fraud, dan FN (False Negative) menyatakan jumlah transaksi fraud yang tidak berhasil terdeteksi oleh model.

Selain metrik tersebut, evaluasi kinerja juga dianalisis menggunakan confusion matrix untuk menggambarkan distribusi prediksi benar dan salah pada masing-masing kelas, dengan perhatian khusus pada kesalahan false negative karena berdampak langsung pada potensi kerugian finansial. Mengingat kedua model menghasilkan keluaran berupa probabilitas transaksi fraud, evaluasi juga dilakukan dengan menerapkan beberapa nilai threshold guna mengamati perubahan nilai precision, recall, dan F1-score pada kondisi data tidak seimbang, sehingga perbandingan kinerja kedua model dapat dilakukan secara lebih komprehensif.

IV. HASIL PENELITIAN

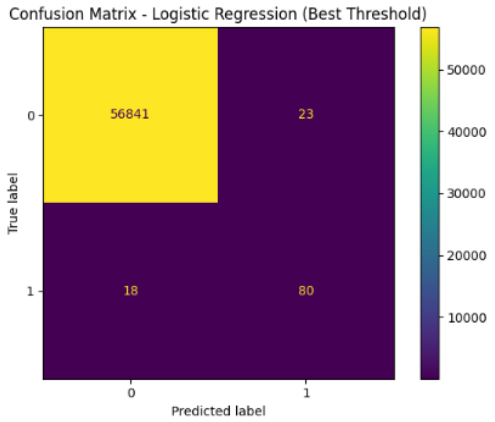
Bagian ini menyajikan hasil evaluasi kinerja model Logistic Regression dan Random Forest dalam mendeteksi transaksi fraud pada dataset kartu kredit yang memiliki distribusi kelas tidak seimbang. Evaluasi dilakukan menggunakan data uji sebesar 20% dari keseluruhan dataset. Hasil disajikan secara objektif dalam bentuk tabel metrik evaluasi dan visualisasi, tanpa interpretasi mendalam.

Tabel 1 menyajikan nilai precision, recall, dan F1-score yang diperoleh oleh masing-masing model pada data uji. Nilai precision menunjukkan proporsi prediksi fraud yang benar, recall menunjukkan kemampuan model dalam mendeteksi transaksi fraud, sedangkan F1-score merepresentasikan keseimbangan antara precision dan recall. Metrik-metrik tersebut digunakan untuk menggambarkan kinerja model secara kuantitatif pada kondisi data yang tidak seimbang.

Tabel 1. Hasil evaluasi kinerja model pada data uji

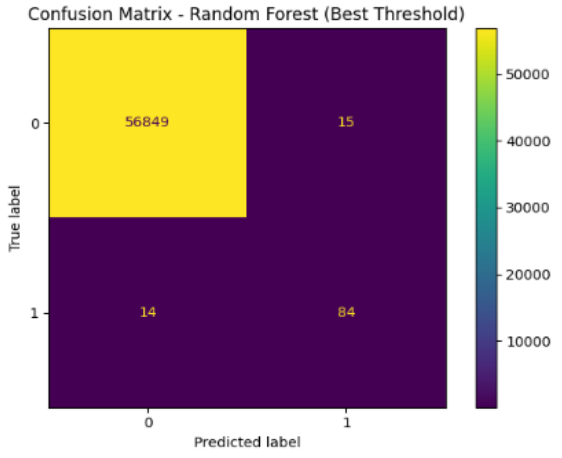
Model	Precision	Recal	F1-score
LR	0.9481	0.7449	0.8343
RF	0.8485	0.8571	0.8528

Untuk memperjelas hasil klasifikasi yang dihasilkan oleh model, evaluasi juga ditampilkan dalam bentuk confusion matrix. Gambar 1 menunjukkan confusion matrix hasil evaluasi model Logistic Regression pada data uji.



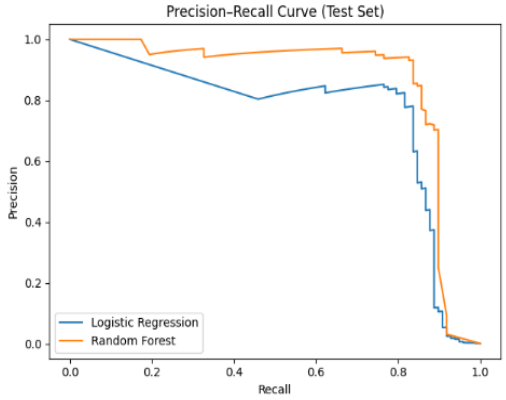
Gambar 1. Confusion matrix hasil evaluasi model Logistic Regression (LR) pada data uji.

Gambar 2 menampilkan confusion matrix hasil evaluasi model Random Forest. Confusion matrix menggambarkan jumlah prediksi benar dan salah untuk masing-masing kelas, termasuk transaksi fraud dan non-fraud



Gambar 2. Confusion matrix hasil evaluasi model Random Forest (RF) pada data uji

Sebagai bagian dari evaluasi kinerja model, Gambar 3 menampilkan precision–recall curve untuk model Logistic Regression dan Random Forest. Grafik ini menunjukkan hubungan antara nilai precision dan recall pada berbagai nilai ambang batas (threshold) berdasarkan probabilitas prediksi model pada data uji, sehingga memberikan gambaran performa model pada kondisi data tidak seimbang.memberikan gambaran performa model pada kondisi data tidak seimbang.



Gambar 3. Precision–recall curve model Logistic Regression (LR) dan Random Forest (RF) pada data uji.

Secara keseluruhan, hasil evaluasi kinerja model Logistic Regression dan Random Forest telah disajikan dalam bentuk metrik evaluasi dan visualisasi pada data uji. Penyajian hasil pada bagian ini bertujuan untuk memberikan gambaran kuantitatif mengenai performa masing-masing model dalam mendeteksi transaksi fraud pada data yang tidak seimbang. Pembahasan lebih lanjut mengenai perbandingan kinerja dan implikasi dari hasil evaluasi tersebut disajikan pada bagian Discussion.

V. PEMBAHASAN

Hasil evaluasi menunjukkan bahwa Random Forest memiliki kinerja yang lebih baik dibandingkan Logistic Regression, terutama ditunjukkan oleh nilai recall dan F1-score yang lebih tinggi. Hal ini mengindikasikan bahwa Random Forest lebih efektif dalam mendeteksi transaksi fraud sebagai kelas minoritas pada data yang sangat tidak seimbang, sehingga berpotensi mengurangi jumlah transaksi fraud yang tidak terdeteksi. Hasil penelitian ini sejalan dengan penelitian terdahulu [3] [7] yang menunjukkan bahwa metode ensemble, khususnya Random Forest, memiliki kinerja yang lebih unggul dalam menangani permasalahan klasifikasi pada data tidak seimbang dan kompleks .

Perbedaan kinerja tersebut dapat dijelaskan oleh karakteristik masing-masing algoritma. Logistic Regression sebagai model linear memiliki keterbatasan dalam menangkap hubungan non-linear dan interaksi kompleks antarfitur pada data transaksi yang heterogen [2] [6]. Sebaliknya, Random Forest, sebagai metode *ensemble* berbasis *decision tree* yang diperkenalkan oleh Breiman [3]

, mampu memodelkan hubungan non-linear dan interaksi antarfitur secara lebih efektif, sehingga lebih adaptif terhadap karakteristik data transaksi yang kompleks.

Meskipun demikian, Logistic Regression tetap relevan sebagai model baseline karena kesederhanaan dan kemudahan interpretasinya. Studi oleh Carcillo *et al.* [2] [6] menunjukkan bahwa Logistic Regression masih banyak digunakan dalam deteksi fraud karena stabilitas performa dan kemampuannya dalam merepresentasikan hubungan antara fitur transaksi dan probabilitas fraud secara transparan.

mplikasi teknis dari hasil penelitian ini menegaskan bahwa pemilihan algoritma dan metrik evaluasi yang tepat sangat penting dalam sistem deteksi fraud pada data tidak seimbang. Random Forest dapat dijadikan alternatif yang lebih andal untuk meningkatkan kemampuan deteksi fraud, sementara penggunaan metrik precision, recall, dan F1-score lebih representatif dibandingkan *accuracy* dalam mengevaluasi kinerja model pada kondisi ketidakseimbangan kelas [8], [9].

VI. KESIMPULAN

Penelitian ini membandingkan kinerja algoritma Logistic Regression (LR) dan Random Forest (RF) dalam mendeteksi fraud transaksi kartu kredit pada data yang sangat tidak seimbang dengan menggunakan metrik precision, recall, dan F1-score. Hasil pengujian pada data uji menunjukkan bahwa Random Forest memiliki kinerja yang lebih baik dibandingkan Logistic Regression, terutama ditunjukkan oleh nilai recall dan F1-score yang lebih tinggi, sehingga lebih efektif dalam mengidentifikasi transaksi fraud sebagai kelas minoritas.

Meskipun demikian, Logistic Regression tetap relevan sebagai model baseline karena kesederhanaan dan kemudahan interpretasinya, meskipun memiliki keterbatasan dalam menangkap pola non-linear pada data transaksi yang kompleks. Kontribusi utama penelitian ini adalah penyajian perbandingan kinerja model linear dan ensemble pada data transaksi yang sangat tidak seimbang menggunakan metrik evaluasi yang sensitif terhadap kelas minoritas. Hasil penelitian ini diharapkan dapat menjadi referensi teknis dalam pemilihan algoritma yang tepat untuk pengembangan sistem deteksi fraud transaksi kartu kredit pada lingkungan data dengan ketidakseimbangan kelas yang tinggi.

VII. REFERENCE

[1] W. Hilal, S. A. Gadsden, and J. Yawney, “Financial Fraud : A Review of Anomaly Detection Techniques and Recent Advances,” *Expert Syst. Appl.*, vol. 193, p. 116429, 2022, doi: 10.1016/j.eswa.2021.116429.

[2] J. L. Leevy, J. Hancock, and T. M. Khoshgoftaar, “Comparative analysis of binary and one - class classification techniques for credit card fraud data,” *J. Big Data*, 2023, doi: 10.1186/s40537-023-00794-5.

[3] C. Fabrizio, D. P. Andrea, L. B. Yann-Aël, C. Olivier, M. Yannis, and B. Gianluca, “SCARFF : a Scalable Framework for Streaming Credit,” *Inf. Fusion*, vol. 41, pp. 182–194, 2021, doi: 10.1016/j.inffus.2017.12.005.

[4] A. A. Compagnino *et al.*, “An Introduction

to Machine Learning Methods for Fraud Detection," no. Ml, pp. 1–32, 2025.

[5] L. H. Aros *et al.*, "machine learning techniques : a literature review," *Humanit. Soc. Sci. Commun.*, pp. 1–22, 2024, doi: 10.1057/s41599-024-03606-0.

[6] B. Eyad Abdel Latif Marazqah, Z. Xujuan, G. Raj, C. Ka Ching, G. Rohan, and S. Prema, "A systematic review of literature on credit card cyber fraud detection using machine and deep learning," vol. 2022, pp. 1–66, 2025, doi: 10.7717/peerj-cs.1278.

[7] I. Y. Hafez, A. Y. Hafez, A. Saleh, A. A. Abd, E. Mageed, and A. A. Abohany, "A systematic review of AI - enhanced techniques in credit card fraud detection," *J. Big Data*, 2025, doi: 10.1186/s40537-024-01048-8.

[8] R. Liu, "Improving Credit Card Fraud Detection in Imbalanced Datasets : A Comparative Study of Machine Learning Algorithms," no. Ecai 2024, pp. 393–397, 2025, doi: 10.5220/0013263900004568.

[9] I. Medarhri, "Reviewing Machine Learning Techniques in Credit Card Fraud Detection," vol. 1, no. Ic3k, pp. 179–187, 2024, doi: 10.5220/0013072500003838.

[10] N. Report, "Card Fraud Losses Worldwide in 2023," 2024. [Online]. Available: https://nilsonreport.com/articles/card-fraud-losses-worldwide-in-2023/%0A